

# Sinir Ağları Sınıflandırma Yöntemi İle Gelir Tahmini

Ecem Öztürk

Bursa Teknik Üniversitesi

**Özetçe—** Bilgiye dayalı endüstride, maaş planlaması, şirket büyümesi ve başarısı için stratejik bir kilitir. Yüksek performanslı çalışanları elde tutabilmek için optimum maaş teklifi şarttır. Mevcut veya muhtemel bir çalışan hakkında çeşitli bilgilere dayanarak bu tür ideal maaş tutarlarının belirlenmesi, şirketlerin çok sık karşılaştığı bir zorluktur. İnsan kaynakları yöneticileri genellikle ilgili departman düzeyindeki yöneticilere danışarak bu tür maaş tahmini ve maaşta uzlaşma konularını ele alsalar da bu tür yeteneklere sahip herhangi bir otomatik sistem onlara çok yardımcı olacaktır. Bir çalışanın (mevcut veya muhtemel) demografik profilini, yeterlilik, performans vb. gibi diğer bilgilerle birlikte içeren nitelikleri göz önüne alındığında, maaş sınıfının tahmini için iyi bilinen birkaç sınıflandırma algoritması kullanılabilir. Ancak ne yazık ki, herhangi bir şirketin çalışan verilerinin bu tür ayrıntıları, sınıflandırma algoritmalarının performans değerlendirmesi için genel olarak kamuya açık değildir. Bu çalışmada, maaş tahmini için bir nüfus kesimin mevcut niteliklerin çoğuna sahip olan bir genel veri tabanı (UCI Adult Income Dataset)<sup>[1]</sup> kullanılarak bu sınırlama bir ölçüde aşılmıştır. Her ne kadar bu deneysel makalede kullanılan veriler doğrudan bir kuruluş içindeki çalışanların maaş tahmini ile ilgili olmasa da UCI sayım veri kümesindeki çalışma alanı ve meslek gibi öznitelikler içerdiğinden, sınıflandırmada kullanılmak üzere tahmin edilebilir. Bu çalışmada geliştirilen yapay sinir ağları sınıflandırıcısı ile %85 oranında doğruluğa ulaşılmıştır.

**Keywords—** Yetişkin Geliri, Maaş Tahmini, Veri Analizi, Sinir Ağı, Sınıflandırma

## I. GİRİŞ

Bilgiye dayalı sanayiye gittikçe daha fazla odaklanarak, beşerî sermaye için tazminat planlaması, şirketlerin sürekli büyüme ve başarı sağlamaları için kilit bir stratejik alan haline geliyor. Şirketlerin bugün karşılaştıkları sorunlardan biri, yüksek performans gösteren çalışanları elde tutma ve diğer kuruluşlardan yetenekli kişileri işe alma zorluğudur. Her iki durumda da maaş hem mevcut hem de potansiyel çalışanları cezbetmek için önemli bir belirleyici faktördür. Bu nedenle, hem çalışan (hem mevcut hem de muhtemel) hem de şirket için karşılıklı kazanç sağlayan en uygun maaş teklifi, çalışanları herhangi bir kuruluşta tutmak veya kuruluşu çekmek için son derece önemlidir. İnsan kaynakları yöneticileri, birçok faktörün bir çalışanın maaş beklentisini etkilediğini ve yalnızca görüşme sırasındaki geçmiş performansının veya performansının beklenen maaşının tek belirleyicisi olmadığını uzun

zamandır fark etmişlerdir. Bu nedenle, işverenlerin bir çalışana nihai teklifte bulunmak için demografik ve diğerleri de dahil olmak üzere çeşitli faktörleri tartmaları gerekir. Deneyimli insan kaynakları yöneticileri bu alıştırmayı ilgili departman düzey yöneticisine danışarak yürütse de bu her zaman zor bir karardır. Her türlü otomatik karar verme sistemi, bu karar vericilerin uygun maaş önerileri bulmaları için son derece yardımcı olacaktır. Genel olarak, şirketler yeni bir işe alımın maaşı için dahili verileri kullanan tazminat tahmin sistemine sahiptir. Ama bu verilerin harici kullanımı böyle bir öngörü sisteminin analizi için kullanılamaz. Bu araştırma makalesinde, Kaliforniya Üniversitesi, Irvine (UCI) deposundan temin edilebilen halka açık bir veri seti, maaş tahmini için makine öğrenme algoritmalarından olan sinir ağları kullanılmıştır. Bu deneysel makalede kullanılan veriler, bir kuruluş içindeki çalışanların maaş tahmini ile doğrudan ilişkili olmasa da, birden fazla kuruluş için çalışan bir nüfus kesiminin ikili maaş sınıfı tahmini ile de ilgilendiği için, önceki senaryoda kullanılmak üzere tahmin edilebilir. Gerçek şirket senaryosunda, maaş sınıfları ikiden fazla olabilir ve nüfus tek bir şirket içinden olacaktır ve dolayısıyla bu açıdan, bu ikili modelleme aynı zamanda gerçek senaryonun bire bir haritalaması değildir. Buna rağmen, bu araştırma makalesinde UCI sayım veri setinde (California Üniversitesi, 1994) sinir ağları algoritmaları kullanılarak yapılan sınıflandırma deneyi, bu algoritmaların gerçek maaş tahmini problemi için etkinliğini anlamak için kesinlikle yararlı bir çaba olarak düşünülebilir. Birden çok sınırlama olsa da bulgular gerçek sorun ayarlarında kullanılabilir.

Genel olarak sınıflandırma, bir veri kümesine bir sınıf etiketi atamak için kullanılan tekniktir. Bu, iş zekâsı uygulamalarında, bir işletmenin, müşterinin, çalışanın vb. verilerinin belirli bir bölümünü veya kaydını etiketlemek için sıklıkla kullanılır. Bu günlerde sınıflandırma, birçok kuruluşta karar verme sürecinin ayrılmaz bir parçası haline gelmiştir. Sınıflandırma, öğrenme adımı ve sınıflandırma adımıyla oluşan iki aşamalı bir süreçtir. Birincisi, eğitim verilerini kullanarak sınıflandırma modelini oluştururken, ikincisi modeli test verileri için uygun etiket / sınıfın tahminini yapmak için kullanır. Karar ağaçları, Naive-Bayes, Destek Vektör Makinesi, Sinir Ağları, Kural Tabanlı Sistemler vb. gibi birçok iyi bilinen sınıflandırma tekniği vardır.

Daha önce de belirtildiği gibi, bu makale bu standart sınıflandırma algoritmalarının bazılarının iyi bilinen bir veri kümesi, yani UCI'den temin edilebilen Yetişkin Gelir veri kümesi üzerindeki karşılaştırmalı performansını araştırmaktadır. Temel amaç, bu algoritmaların bir kuruluşun çalışanlarının (mevcut veya muhtemel) maaş tahmini için uygulanabilirliği ve karşılaştırmalı performans rakamları hakkında net bir anlayış geliştirmektir.

## II. İLGİLİ ÇALIŞMA

Bu makalede elde edilen sonuçları kıyaslama amacıyla UCI'den alınan 'Yetişkin Gelir' veri seti ile 'Neural Network Application in Income Classification'<sup>[2]</sup> Research' adlı makaleyi yazmış olan Tianyu Li adlı öğrenci tarafından Sinir Ağları algoritmaları kullanılarak bir sınıflandırma yapılmıştır. İlgili makalede modelin yaptığı tahminin doğruluk oranını yaklaşık olarak %85 olduğu rapor edilmiş, bu oranın ayrıntılı ondalık değerine ulaşılamamıştır.

## III. YETİŞKİN GELİR VERİ SETİ

Bu çalışmada kullanılan veri seti, bireysel maaş sınıfları da dahil olmak üzere 32.561 kişilik bir nüfusun her bir üyesi için on beş demografik özellik içermektedir. Veri kümesi herhangi bir şirkete özgü değildir ve bu nedenle herhangi bir performans özniteliği içermez. Bir kişi için 50 Bin ABD Dolarından (> 50 Bin) büyük ve 50 Bin ABD Dolarından (<= 50 Bin) küçük veya ona eşit iki olası maaş sınıfı vardır. Veri kümesindeki verilerin yaklaşık %30'u >50K sınıfına, geri kalan %70'i <=50K kategorisine ait olduğundan, bu veri kümesi bu iki maaş sınıfının sayıları açısından dengeli değildir. Veri seti, öncelikle beyaz kategoriye (27,816) ait özel şirketlerin erkek işçilerine (21,790) ilişkin verileri içermektedir.

Tüm verilerin öznitelikleri sıralı halde gösterilecek olursa :

Data columns (total 15 columns):			
#	Column	Non-Null Count	Dtype
0	age	48842 non-null	int64
1	workclass	48842 non-null	category
2	fnlwgt	48842 non-null	int64
3	education	48842 non-null	category
4	educational-num	48842 non-null	int64
5	marital-status	48842 non-null	category
6	occupation	48842 non-null	category
7	relationship	48842 non-null	category
8	race	48842 non-null	category
9	gender	48842 non-null	category
10	capital-gain	48842 non-null	int64
11	capital-loss	48842 non-null	int64
12	hours-per-week	48842 non-null	int64
13	native-country	48842 non-null	category
14	income	48842 non-null	category

Resim 1 : Öznitelikler

Resim 1'de gösterildiği üzere veriler 14 adet kategoride (15. Kategori olan gelir özniteliği sayılmamıştır) incelenmiştir. Bu kategorilere örnek olarak yaş, eğitim durumu, aile ilişki durumu (daha önce hiç evlenmemiş, evleniş koca, evlenmiş baba..) , anavatani, hafta başına çalışma saati vb. örnek verilebilir.

## IV. VERİ İŞLEMLERİ

### 1. VERİ ÖN ANALİZİ

Orijinal veriler toplamda 14 öznitelik ve 48842 örnek içerir. Eğitim verilerinde 32561 örnek ve test verilerinde 16281 örnek bulunmaktadır. Veri kümesi, bireylerin gelir düzeyini tahmin etmek ve kişisel gelir düzeyini yılda 50 bin ABD doları olarak sınıflandırmak için temel sağlar. Sinir ağını tasarlamaya başlamadan önce, verilerin ön işleme tabi tutulması gerekir. Sayım veri kümesinin ağ eğitimi amacıyla yeterli örneği vardır ve kategorik ve sürekli sayısal özniteliklerin birleşimidir. Tahmin problemi, sinir ağı yönteminin benimsenmesi için uygun olan tipik bir sınıflandırma problemidir.

	age	workclass	fnlwgt	education	educational-num	marital-status	occupation	relationship	race	gender
0	25	Private	226802	11th	7	Never-married	Machine-op-inspct	Own-child	Black	Male
1	38	Private	89814	HS-grad	9	Married-civ-spouse	Farming-fishing	Husband	White	Male
2	28	Local-gov	336951	Assoc-acdm	12	Married-civ-spouse	Protective-serv	Husband	White	Male
3	44	Private	160323	Some-college	10	Married-civ-spouse	Machine-op-inspct	Husband	Black	Male
4	18	?	103497	Some-college	10	Never-married	?	Own-child	White	Female

Resim 2 : Verilerin Tablosu

### 2. VERİ TEMİZLEME

Yukarıda verilen Resim 2'ye bakıldığında 4. Satırdaki ham verilerin bazı eksik değerler (?) içerdiği fark edilir. Eksik olmayan diğer değerlerin tamlığı bozulacağından, bazı verilerin eksik olduğu satırları silmek uygun değildir. Bu nedenle, veri temizleme tekniklerini kullanarak eksik değerleri ele almamız gerekiyor.

workclass: 2799 records  
occupation: 2809 records  
native-country: 857 records

Resim 3 : Kayıp Değerler

Veri seti içinde soru işareti (?) ile doldurulan özellikler kayıp değer anlamındadır. Yukarıda verilen Resim 3'e bakıldığında tüm veri seti içinde 'workclass' olarak adlandırılan çalışma sınıfı özniteliğinde toplam 2799 kayıp değer, 'occupation' olarak adlandırılan meslek özniteliğinde toplam 2809 kayıp değer ve 'native-country' olarak adlandırılan anavatan özniteliğinde de toplam 857 kayıp değer olduğu görülmektedir.

### 2.1 Kayıp Değerlerin Doldurulması

Bu çalışmada, üç sütunun her birindeki eksik değerleri tahmin etme metodları kullanılarak doldurulmuştur. Üç sütunun her biri için, tüm öznitelikleri ('income (gelir)' dahil) bağımsız değişkenler olarak kullanılmıştır ve bu sütunu bağımlı değişken olarak ele alınıp çok sınıflı sınıflandırma görevi yapılmıştır. Değer eksik olduğunda sınıfı tahmin etmek için lojistik regresyon, karar ağaçları ve rastgele orman olmak üzere üç sınıflandırma algoritması kullanılmıştır. Ardından eksik değerlerin sınıfını seçmek için üç sınıflandırıcı arasındaki çoğunluk oyu alınmıştır. Bir eşitlik durumunda, tüm veri kümesini kullanarak bu sütunun çoğunluk sınıfını (majority class) seçilmiştir.

### 3. Veri Dönüşümleri

Education-num	Education
1	Preschool
2	1st-4th
3	5th-6th
4	7th-8th
5	9th
6	10th
7	11th

Tablo 1 : Eğitim verileri

Yukarıda verilmiş olan Tablo 1’de görüldüğü gibi, bağışçı tarafından sağlanan veriler, bağımsız sayısal nitelikler getirilerek kısmen kodlanmıştır. Örneğin eğitim düzeyi için, education\_num (eğitim numarası) özniteliği ile bitişik education (eğitim) özniteliği mevcuttur ve bunlar aynı tür kavramları temsil eder. Bu sebeple öznitelik bilgisini saptırmamak adına tablodan "education" özniteliğini çıkarılmıştır.

	age	workclass	educational-num	marital-sta
0	25	Private	7	Never-mar
1	38	Private	9	Married-civ-spo
2	28	Local-gov	12	Married-civ-spo
3	44	Private	10	Married-civ-spo

Resim 4 : "Education" özniteliği çıkarıldı

### 4. Normalizasyon

Bir sinir ağı oluşturmak için, veriler uygun bir düzende olmalıdır. Normalizasyon sıklıkla kullanılan veri ölçekleme ve haritalama tekniğidir. Verilerin özelliklerini normalleştirme, önceden karar verilen aralıklardaki tüm özelliklerin değerlerini sınırlamak için yararlı bir adımdır. Veri seti içinde birçok özellik var olabilir ve bu özelliklerin boyutları farklı olabilir. Boyutu büyük olan değer sınıflandırma işleminde daha büyük ağırlığa neden olabilir ve sınıflama doğruluğunu o ekseninde kaydırabilir. Fakat doğruluk ağırlığı küçük olan bir değer tarafında da olabilir. Bu nedenle veri içindeki her özellik yaklaşık olarak eşit aralığa ve aynı etkiye sahip olmalıdır. [3]

Kategorik verilerin tümü uygun bir şekilde kodlanmalıdır. "One Hot Encoding" kodlama deseni, sinir ağı oluşturma için uygundur, çünkü 0 veya 1 değerine sahip bir grup sütun, tek bir kategorik değeri tanımlamak için aynı anda çalışır. Aynı sütundaki bir sayı dizisine değer vermekle karşılaştırıldığında, bir-sıcak-kodlama deseni (one-hot encoding) karar işlevleri tarafından daha iyi işlenebilir. One Hot Encoding, kategorik değişkenlerin ikili (binary) olarak temsil edilmesi anlamına gelmektedir. Bu işlem ilk önce kategorik değerlerin tamsayı değerleriyle eşlenmesini gerektirir. Daha sonra, her bir tamsayı değeri, 1 ile işaretlenmiş tamsayı indeksi dışında ki tüm değerleri sıfır olan bir ikili vektör olarak temsil edilir. Bir One Hot Encoding, kategorik verilerin temsilinin daha etkileyici ve kolay olmasını sağlar.

Color	Red	Yellow	Green
Red	1	0	0
Red	1	0	0
Yellow	0	1	0
Green	0	0	1
Yellow	0	0	1

Resim 5 : Bir one-hot encoding örneği

Yukarıda verilen Resim 5’de görüldüğü gibi çeşitli öznitelikler 0-1 skalasına düşürülebilir. Örneğin, bu çalışmada kullanılan veri setinde "iş alanı" özniteliği için 8 farklı özellik(workclass\_private, workclass\_self\_emp\_not, is\_self\_emp\_inc, is\_federal\_gov, is\_local-gov, is\_state-gov, is\_without-pay, is\_never-worked.) vardır. Bu aşamada, one-hot encoding dönüşümü bize kolaylık sağlayacaktır.

## V. METODOLOJİ

### 1. Yapay Sinir Ağları

Yapay sinir ağları (YSA), insan beyninin bilgi işleme tekniğinden esinlenerek geliştirilmiş bir bilgi işlem teknolojisidir. YSA ile basit biyolojik sinir sisteminin çalışma şekli taklit edilir. Yani biyolojik nöron hücrelerinin ve bu hücrelerin birbirleri ile arasında kurduğu sinaptik bağın dijital olarak modellenmesidir.[1] Nöronlar çeşitli şekillerde birbirlerine bağlanarak ağlar oluştururlar. Bu ağlar öğrenme, hafızaya alma ve veriler arasındaki ilişkiyi ortaya çıkarma kapasitesine sahiptirler. Diğer bir ifadeyle, YSA'lar, normalde bir insanın düşünme ve gözlemlemeye yönelik doğal yeteneklerini gerektiren problemlere çözüm üretmektedir. Bir insanın, düşünme ve gözlemleme yeteneklerini gerektiren problemlere yönelik çözümler üretebilmesinin temel sebebi ise insan beyninin ve dolayısıyla insanın sahip olduğu yaşayarak veya deneyerek öğrenme yeteneğidir. [4]

Bir sinir ağındaki nöron, n sayıda girdi alan ve tek bir çıktı üreten temel hesaplama birimidir. Bir yapay nöron x girdilerin, w ağırlıkları toplamını hesaplar ve bias değeri ekleyerek aşağıdaki gibi bir y çıktısı üretir:

$$y = \text{Aktivasyon}(\sum(w \cdot x + b))$$

Aktivasyon fonksiyonu burada y değerini kontrol etmek için yani bir nöronun aktif olup olmayacağına karar vermek için kullanılmaktadır. Aktivasyon fonksiyonları, bu yönüyle derin sinir ağları için önemli bir özelliktir. [5] Bu çalışmada, ReLU (Rectified Linear Unit) Fonksiyonu, Hiperbolik Tanjant Fonksiyonu, Özdeşlik Fonksiyonu (Identity Function) ve Log-Sigmoid Fonksiyonu (Log-Sigmoid Activation Function) kullanılmıştır.

#### 1.1 Kullanılan Aktivasyon Fonksiyonları

##### 1.1.1 ReLu

Doğrultulmuş lineer birim (rectified linear unit- RELU) doğrusal olmayan bir fonksiyondur. ReLU fonksiyonu negatif girdiler için 0 değerini alırken, x pozitif girdiler için x değerini almaktadır. [6]

##### 1.1.2 Hiperbolik Tanjant Fonksiyonu

$[-1,1]$  aralığında çıktı üreten doğrusal olmayan bir fonksiyondur.

### 1.1.3 Özdeşlik Fonksiyonu

Kimlik veya Doğrusal Aktivasyon Fonksiyonu olarak da bilinir. En basit aktivasyon fonksiyonlarından biridir. Verilere özdeşlik işlemi uygular ve çıktı verilerini giriş verileriyle orantılıdır. Doğrusal aktivasyon fonksiyonu ile ilgili problem, türevinin sabit olması ve gradyanının da sabit olması ve inişin sabit bir gradyan üzerinde olmasıdır.

### 1.1.4 Log-Sigmoid Fonksiyonu

En yaygın kullanılan aktivasyon fonksiyonlarından birisidir,  $[0,1]$  aralığında çıktı üretir.

## 1.2 Kullanılan Optimizasyon Metodları

### 1.2.1 Adam Optimizasyon Algoritması

Adam, eğitim verilerine dayalı yinelemeli ağırlıkların güncellemek için kullanılabilecek bir optimizasyon algoritmasıdır.

### 1.2.2 Alpha

Öğrenme hızı veya adım boyutu olarak da adlandırılır. Ağırlıkların güncellendiği oran (örneğin 0.001). Daha büyük değerler (örneğin 0,3), oran güncellenmeden önce daha hızlı ilk öğrenmeyle sonuçlanır. Daha küçük değerler (örneğin  $1.0E-5$ ) eğitim sırasında öğrenmeyi yavaşlatır.

## VI. MODEL GELİŞTİRME

ANN using TanH and lbfgs solver : 85.50 percent.  
ANN using relu and adam solver : 85.58 percent.  
ANN using logistic and adam solver : 85.61 percent.  
ANN using identity and adam solver : 85.28 percent.

	accuracy	precision	recall	f_measure	sensitivity	specificity	error_rate
ANN_TanH	0.8550	0.7273	0.6139	0.6658	0.6139	0.9292	0.145
ANN_relu	0.8558	0.7230	0.6271	0.6716	0.6271	0.9261	0.144
ANN_log	0.8561	0.7210	0.6334	0.6743	0.6334	0.9246	0.143
ANN_identity	0.8528	0.7251	0.6024	0.6580	0.6024	0.9298	0.147

Resim 6 : Modelin Sonuçları


Oluşturduğumuz modelin verdiği sonuçlar Resim 6'da verilmiştir. Buna göre en iyi F puanına (f\_measure) ve doğruluk (accuracy) değerine sahip öngörü 'ANN\_log' ile yapılan model olmuştur. Aynı zamanda en düşük hata payına ('error\_rate') da ANN\_log sahiptir.

## VII. ROC EĞRİSİ

Sinyal algılama teorisinde, alıcı işletim karakteristiği (orijinal adıyla; Receiver Operating Characteristic - ROC) ya da sade biçimde ROC eğrisi olarak tanımlanmaktadır. ROC eğrisi, ikili sınıflandırma sistemlerinde ayırım eşik değerinin farklılık gösterdiği durumlarda, hassasiyetin kesinliliğe olan oranıyla

ortaya çıkmaktadır. ROC daha basit anlamda doğru pozitiflerin, yanlış pozitiflere olan kesri olarak da ifade edilebilir.[1]).

Her sınıflandırma işleminde yapıldığı gibi, metotlar kesinlik (yanlış pozitifleri eleme kabiliyeti) ve hassasiyet (doğru pozitifleri tespit etme kabiliyeti) arasındaki dengeyi kurmakla uğraşmaktadır. Veri kümesindeki pozitif ve negatif örnekler, eşit bir şekilde dağılım göstermediğinden dolayı, doğrudan kesinlik ve hassasiyet ölçütlerinden önce, ROC kısaltması ile Receiver Operating Characteristics (Use of receiver operating characteristic (ROC) analysis to evaluate sequence matching, Gribskov and Robinso, Elsevier, 1996) adı verilen eğri, kesinlik ve hassasiyet arasındaki dengeyi değerlendirmek için kullanılmıştır. ROC eğrisi altında kalan alan ROC puanı olarak tanımlanabilir. ROC eğrisi değişen sınıflandırma eşik değerlerine göre doğru pozitiflerin sayısının, yanlış pozitiflerin bir fonksiyonu olarak çizilmesiyle oluşmaktadır. ROC puanı 1 (bir) olduğunda anlamı, pozitifler mükemmel bir şekilde negatiflerden ayrılmıştır, olmaktadır. ROC puanı 0 (sıfır) olduğunda ise herhangi bir pozitif bulunamadı anlamına gelir.



Resim 7 : Oluşturulan Modelin Roc Eğrisi

İlk 3 model için karar vericinin etkinliği eğrisinin Resim 7'de gösterilen grafiği; lojistik aktivasyon fonksiyonlu ANN, relu aktivasyon fonksiyonlu ANN ve TANH aktivasyon fonksiyonlu ANN.

Şekilden, lojistik aktivasyon fonksiyonlu ANN modelinin ROC eğrisinin en yüksek kaldırmaya sahip olduğunu ve arsanın sol üst köşesine (1'in TPR'Sİ ve 0'ın FPR'Sİ) en yakın olduğunu görebiliriz.

## VIII. SONUÇ

Tüm bu modeller göz önüne alındığında, araştırma sonucunda lojistik aktivasyon fonksiyonlu ANN modelini seçilmiştir. Lojistik aktivasyon fonksiyonlu ANN modeli sadece en yüksek doğruluğa sahip olmakla kalmaz, aynı zamanda bu analizin bir parçası olarak geliştirilen tüm modellerin en yüksek hassasiyetine ve F ölçüsüne sahiptir.

## KAYNAKÇA

- [1] <http://archive.ics.uci.edu/ml/datasets/adult>
- [2] [http://users.cecs.anu.edu.au/~Tom.Gedeon/conf/ABCs2018/paper/ABCs2018\\_paper\\_181.pdf](http://users.cecs.anu.edu.au/~Tom.Gedeon/conf/ABCs2018/paper/ABCs2018_paper_181.pdf)
- [3] <https://dergipark.org.tr/tr/download/article-file/2034430>
- [4] [https://tr.wikipedia.org/wiki/Yapay\\_sinir\\_a%C4%9Flar%C4%B1](https://tr.wikipedia.org/wiki/Yapay_sinir_a%C4%9Flar%C4%B1)
- [5] <http://buyukveri.firat.edu.tr/2018/04/17/derin-sinir-aglari-icin-aktivasyon-fonksiyonlari/>
- [6] <http://buyukveri.firat.edu.tr/2018/04/17/derin-sinir-aglari-icin-aktivasyon-fonksiyonlari/>
- [7] <https://tr.wikipedia.org/wiki/ROC>

-